

# Information Retrieval

# គំនុគិន គីត គំនឧទ្វារ គីនឧទ្វារ

- វិធីការใช้ Dictionary បន Python
- អង់គ្លេសីវិភាគ ឬយុទ្ធសាស្ត្រ
- អីមែល់ខិត្តូរបៀវត្ស ឬសំណង់សារ
- រូបភាពរបស់ខ្លួន
- រតិថ្លើប្រព័ន្ធអីមែល់

# Information Retrieval การค้นคืนข้อมูล

material


collection

information need

- การค้นหา เนื้อหา จาก กองข้อมูล ที่ตอบโจทย์ ความต้องการทางข้อมูล

(Information need)

# Classic Search Model



# NLP + Information Retrieval

query

document

- "รถไฟฟ้าเปิดกี่โมง" ---> 

BTS เริ่มวิ่งกี懵ครับ - Pantip  
<https://pantip.com/topic/37607959> ▾ Translate this page  
Apr 27, 2018 - ... btsสะพานความ-bts โพธินิมิต ไม่ทราบว่าbtsเริ่มวิ่งตั้งแต่กี懵ครับ ขอบคุณครับ. ... สำหรับเวลาการให้บริการของรถไฟฟ้าบีทีเอสเที่ยวแรกจะออกจากสถานีหมอชิต .... สถานีแบริ่ง ไป หมอชิตใช้เวลา กี่นาที หรือครับ และรถไฟ bts นี่เปิดให้บริการ ตอน 6:00 ...
- "รถไฟฟ้าเปิดกี่โมง" ---> รถไฟฟ้า BTS สายสุขุมวิทเปิดเวลา 5:15

who's the prime minister of thailand

**All**

Images

News

Maps

Videos

More

Settings

Tools

About 69,300,000 results (1.13 seconds)

Thailand / Prime minister

# Prayut Chan-o-cha

Since 2014



Prayut Chan-o-cha is a Thai politician, retired Royal Thai Army general officer, head of the National Council for Peace and Order, and concurrently serves as the Prime Minister of Thailand. [Wikipedia](#)

# Document เอกสาร

- วิธีการใช้ Dictionary บน Python
- หนังสือเรื่อง อุยู่กับกง
- อีเมล์เชิญไปสัมภาษณ์งาน
- รูปภาพของเมօปราง
- รถไฟฟ้าเปิดกีโมง






## ป้าข้าวเหนียวไก่อั้กเบร

4.0 ★ 26 รีวิว ₩ ปอดอยู่

อาหารจานเดียว, อาหารไทย  
เมนูเด็ด: ข้าวเหนียวไก่ทอด, ข้าวเหนียวไก่ทอด



a g o d a



2017 Baiyoke Sky Hotel

★★★★★ HOTEL | Pratunam, Bangkok - View on map

Excellent location

Breakfast 2+

Price includes Free cancellation

Special discount on your first booking

Recommended by 82% of guests

Popular now! Last booked 5 hours ago

Our last room at this price!

Coupon code 24HOURSAL applied - ₩ 132 off!



smartmi 智米

pre order เครื่องวัด PM 2.5



1660.-

# Challenges

- ทำความเข้าใจ query และ document เพื่อสนองความต้องการทางข้อมูลของผู้ใช้
- ต้องทำให้ได้เร็ว (อย่าเกิน 1-2 วินาที)
- ต้องอย่าเปลืองที่เก็บข้อมูลและเครื่องคอมพ์

# **Boolean Retrieval**

# Search แบบง่ายสุด

- อยากรู้ไฟล์ที่มีคำว่า Caesar และคำว่า Brutus  
`grep 'Caesar' docs/*.txt | grep 'Brutus'`
- อยากรู้ไฟล์ที่มีคำว่า Caesar และ Brutus แต่ไม่มีคำว่า Calpurnia

term-document

document

term

not

ANTHONY

BRUTUS

CAESAR

CALPURNIA

CLEOPATRA

MERCY

WORSER

...

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	1	1	0	0	0	1	...
BRUTUS	1	1	0	0	0	0	...
CAESAR	1	1	0	0	1	1	...
CALPURNIA	0	1	0	0	1	0	...
CLEOPATRA	1	0	0	0	0	0	...
MERCY	1	0	1	1	1	1	...
WORSER	1	0	1	1	1	0	...
...	1	1	0	1	0	0	...

Anthony & Julius Caesar  
Hamlet  
Othello  
Macbeth

# Term-Doc Matrix ในความเป็นจริง

- $N = 1$  ล้าน document แต่ละ doc มี 1000 คำ
- ค่าเก็บข้อมูล
  - ตัวอักษรละ 1 byte คำนึงมีประมาณ 6 ตัวอักษรโดยเฉลี่ย
  - ต้องใช้ Hard drive ขนาด 1 byte  $\times$  6  $\times$  1000  $\times$  1M = 6000MB = 6GB
  - ค่าเก็บข้อมูล term-doc matrix

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	1	1	0	0	0	1	
BRUTUS	1	1	0	1	0	0	
CAESAR	1	1	0	1	1	1	
CALPURNIA	0	1	0	0	0	0	
CLEOPATRA	1	0	0	0	0	0	
MERCY	1	0	1	1	1	1	
WORSER	1	0	1	1	1	0	
...							

- 4 bytes x 1M document x 100,000 (vocab size) = 400GB


99% ของ 400GB เก็บแต่ 0 เօაໄວ້


# Inverted Index

# Inverted Index

- data structure ที่เป็น sparse matrix แบบหนึ่ง search engine  
ทุกประเภทบนโลกนี้ยังใช้กันอยู่
- จุดมุ่งหมาย คือ ประหยัดที่และประหยัดเวลา

# Inverted Index






## case folding


**Doc 1.** I did enact Julius Caesar: I  
was killed i' the Capitol; Brutus killed  
me.

**Doc 2.** So let it be with Caesar. The  
noble Brutus hath told you Caesar  
was ambitious:




**Doc 1.** i did enact julius caesar i was  
killed i' the capitol brutus killed me  
**Doc 2.** so let it be with caesar the  
noble brutus hath told you caesar was  
ambitious

**Doc 1.** i did enact julius caesar i was  
killed i' the capitol brutus killed me  
**Doc 2.** so let it be with caesar the  
noble brutus hath told you caesar was  
ambitious



# Brutus and Calpurnia

# ❧ BRUTUS



ପ୍ରକାଶନ କମିଶନ୍ସନ୍

$\approx$  add to result } 2, 31 }

$\text{INTERSECT}(p_1, p_2)$

```
1  answer  $\leftarrow \langle \rangle$ 
2  while  $p_1 \neq \text{NIL}$  and  $p_2 \neq \text{NIL}$ 
3  do if  $\text{docID}(p_1) = \text{docID}(p_2)$  —
4      then  $\text{ADD}(\text{answer}, \text{docID}(p_1))$  —
5           $p_1 \leftarrow \text{next}(p_1)$  —
6           $p_2 \leftarrow \text{next}(p_2)$  —
7      else if  $\text{docID}(p_1) < \text{docID}(p_2)$  —
8          then  $p_1 \leftarrow \text{next}(p_1)$  —
9          else  $p_2 \leftarrow \text{next}(p_2)$  —
10 return answer
```

# Linguistic Processing of Documents

# From words to terms

- แปลงเอกสาร (e.g. email, PDF, word doc) ให้เป็น text file ธรรมดा
- Tokenize: *honey-roasted pork*      *colour, color* → *color*
- Normalization: *U.S.A*, *USA* → *usa*; *naïve*, *naive* → *naive*
- Stemming: *authorization*, *authorize*, *authorized* → *authoriz*
- Stopwords: *the*, *a*, *to*, *of*, *in* → X

# Tokenize ภาษาไทย: ผลิตรายการ

- Word segmentation with Machine Learning : ผลิต, ราย, การ
- Dictionary : ผลิต, ราย, การ, ลิตร
- Character cluster: ผลิต, ราย, การ
- Character ngrams: ผล ลิต ตร รา ยก กา { ผล ลิต ตร รา ยก กา

# Thai Character Cluster

<TCC> → ‘ິ’ | ‘ີ’ | ‘ຶ’  
| <Cons> ‘ຣຣ’ ,<Cons> ‘່’ ,  
| <Cons> <BCons> <Cons> ‘່’ ,  
| <Cons> <TCC1> <Karan>  
| <FSara><Cons> <TCC2> <Karan>

<TCC1> → <DSara> {<Tone>}  
| {<Tone>} ‘່’  
| [‘້’ | ‘໌’] {<Tone>} <BCons>  
| ‘້’ {<Tone>[‘້’ | ‘໌’]}  
| ‘້’ <BCons>  
| <Tone>[<TSara>|<DSara>]{‘່’} <BCons>

<TCC2> → <Cons> ‘່’  
| ‘້’ <BCons>  
| <USara> {<Tone>} <BCons> [‘່’ | ‘້’]  
| {<Tone>} [‘່’ | ‘້’ | ‘໌’]

| {<Tone>} <Bsara>  
| NULL

<Karan> → <Cons> {<Cons>} {[<DSara> | ‘້’]} ‘່’ ,  
| NULL

# From words to terms

- แปลงเอกสาร (e.g. email, PDF, word doc) ให้เป็น text file ธรรมดា
- Tokenize
- Normalization
- Stemming
- Stopwords

# Phrase Queries

# Phrase Query

- หา document ที่มีคำว่า Stanford University อญ্তิดกัน
  - ไม่เอา doc "I went to university at Stanford"

**Doc 1.** i did enact julius caesar i was  
killed i' the capitol brutus killed me  
**Doc 2.** so let it be with caesar the  
noble brutus hath told you caesar was  
ambitious

term	docID
i	1
did	1
enact	1
julius	1
caesar	1
i	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

term	docID
ambitious	2
be	2
brutus	1
brutus	2
capitol	1
caesar	1
caesar	2
caesar	2
did	1
enact	1
hath	1
i	1
i'	1
it	2
julius	1
killed	1
killed	1
let	2
me	1
noble	2
so	2
the	1
the	2
told	2
you	2
was	1
was	2
with	2

term	doc.	freq.	→	postings lists
ambitious	1		→	2
be	1		→	2
brutus	2		→	1 → 2
capitol	1		→	1
caesar	2		→	1 → 2
did	1		→	1
enact	1		→	1
hath	1		→	2
i	1		→	1
i'	1		→	1
it	2		→	2
julius	1		→	1
killed	1		→	1
let	1		→	2
me	1		→	1
noble	1		→	2
so	1		→	2
the	2		→	1 → 2
the	2		→	2
told	1		→	2
you	2		→	2
was	1		→	1 → 2
was	2		→	2
with	1		→	2

# Phrase query ที่ยาวกว่า 2 คำ

- Stanford University Palo Alto →  
"Stanford University" AND "University Palo" AND "Palo Alto"

# Biword Index ไม่ใช่คำต่อบ

- Index จะใหญ่เบิ้มมากเสียค่าเก็บ (อย่าลืมว่า RAM แพง)
- ไม่รองรับ phrase ที่ยาวกว่าสองคำ

# Positional Index

- (term, freq): [docID, docID, docID, ...]
- (term, freq): [docID: [word position, word position, ...] ,  
docID: [word position, word position, ...] , ... ]

Query: “*to*<sub>1</sub> *be*<sub>2</sub> *or*<sub>3</sub> *not*<sub>4</sub> *to*<sub>5</sub> *be*<sub>6</sub>”

TO, 993427:

```
⟨ 1: ⟨7, 18, 33, 72, 86, 231⟩;
  2: ⟨1, 17, 74, 222, 255⟩;
  4: ⟨8, 16, 190, 429, 433⟩;
  5: ⟨363, 367⟩;
  7: ⟨13, 23, 191⟩; . . . ⟩
```

BE, 178239:

```
⟨ 1: ⟨17, 25⟩;
  4: ⟨17, 191, 291, 430, 434⟩;
  5: ⟨14, 19, 101⟩; . . . ⟩
```

# Positional Index ແພ້ໄປມີ

Query: “*to<sub>1</sub> be<sub>2</sub> or<sub>3</sub> not<sub>4</sub> to<sub>5</sub> be<sub>6</sub>*”

TO, 993427:

```
⟨ 1: ⟨7, 18, 33, 72, 86, 231⟩;
  2: ⟨1, 17, 74, 222, 255⟩;
  4: ⟨8, 16, 190, 429, 433⟩;
  5: ⟨363, 367⟩;
  7: ⟨13, 23, 191⟩; ... ⟩
```

BE, 178239:

```
⟨ 1: ⟨17, 25⟩;
  4: ⟨17, 191, 291, 430, 434⟩;
  5: ⟨14, 19, 101⟩; ... ⟩
```

# สรุป

- ใช้ทั้งสองอย่างไปเลย
  - positional index มันช้า ==> phrase ในบที่เจอบ่อยๆ ก็เก็บไว้ใน phrase index (caching)

# **Ranked Retrieval with TF-IDF**

# Boolean Search

- ไม่เข้า ก็ออกเลย
- ไม่酵ะไป (ขี้เกียจเปิดอ่านหมด) ก็น้อยไป (ไม่มีสิ่งที่อยากได้)



All

Images

Maps

Videos

News

More

Settings

Tools

About 495,000 results (0.62 seconds)

## คณะอักษรศาสตร์ เรียนเกี่ยวกับอะไรหรือคะ? - Pantip

<https://pantip.com/topic/36869921> ▾ Translate this page

Sep 13, 2017 - แล้วการสอบเข้าต้องมีสอบอะไรบ้างหรือคะ พอดีว่าสนใจมาก็และอยากเรียนอะไร เป็นคนชอบภาษาจีนแต่ไม่รู้จะเข้าคณะอะไร เลยอยากรู้อะไรค่ะว่าคณะ อักษรฯ ...

## คณะอักษรศาสตร์ – จุฬาลงกรณ์มหาวิทยาลัย

<https://www.chula.ac.th/academic/faculty-of-arts/> ▾ Translate this page

ภาควิชาของคณะอักษรศาสตร์ (Faculty of Arts). คณะอักษรศาสตร์ประกอบด้วย 11 ภาควิชา ได้แก่. 1. บรรณารักษศาสตร์ (Library Science); 2. ประวัติศาสตร์ (History); 3. ปรัชญา ...

# Relevance Score คือแนวความเกี่ยวข้อง

The screenshot shows a search results page from a search engine. The search query "คณะอักษรศาสตร์" is entered in the search bar, accompanied by a microphone and magnifying glass icon. Below the search bar are navigation links: All (highlighted in blue), Images, Maps, Videos, News, More, Settings, and Tools. A message indicates "About 506,000 results (0.50 seconds)".

**Result 1:** [คณะอักษรศาสตร์ เรียนเกี่ยวกับอะไรหรือคะ? - Pantip](https://pantip.com/topic/36869921)  $score(d_1, q) = 0.81$   
The result is a link to a Pantip topic. The snippet shows: "Sep 13, 2017 - แล้วการสอบเข้าต้องมีสอบอะไรบ้างหรือคะ พอดีว่าสนใจอยากเรียนอะไร เป็นคนชอบภาษาจีนคะแต่ไม่รู้จะเข้าคณะอะไร เลยอยากรู้อะไรค่ะ อักษรฯ ...".

**Result 2:** [คณะอักษรศาสตร์ – จุฬาลงกรณ์มหาวิทยาลัย](https://www.chula.ac.th/academic/faculty-of-arts/)  $score(d_2, q) = 0.74$   
The result is a link to the Faculty of Arts website at Chulalongkorn University. The snippet shows: "ภาควิชาของคณะอักษรศาสตร์ (Faculty of Arts). คณะอักษรศาสตร์ประกอบด้วย 11 ภาควิชา ได้แก่. 1. บรรณารักษศาสตร์ (Library Science); 2. ประวัติศาสตร์ (History); 3. ปรัชญา ...".

**Result 3:** [คณะอักษรศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย - ผู้ที่ต้องการเข้าศึกษา](https://www.arts.chula.ac.th/prospective/prospective.html)  $score(d_3, q) = 0.68$   
The result is a link to the prospective students section of the Faculty of Arts website. The snippet shows: "ระดับปริญญาตรี. มีคนจำนวนไม่น้อยที่เข้าใจว่า อักษรศาสตร์ เรียนภาษา ความจริงแล้ว รายวิชาประมาณ 2 ใน 5 ของรายวิชาที่นิสิตอักษรศาสตร์ต้องเรียนในคณะนั้น ...".

# ถ้าเห็น term นั้นบอย doc นั้นยิ่งคะแนนเยอะ

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet		Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet
ANTHONY	1	1	0	0	ANTHONY	157	73	0	0
BRUTUS	1	1	0	1	BRUTUS	4	157	0	2
CAESAR	1	1	0	1	CAESAR	232	227	0	2
CALPURNIA	0	1	0	0	CALPURNIA	0	10	0	0
CLEOPATRA	1	0	0	0	CLEOPATRA	57	0	0	0
MERCY	1	0	1	1	MERCY	2	0	3	8
WORSER	1	0	1	1	WORSER	2	0	1	1
...									

q = Anthony Brutus

# Term Frequency

- Frequency = Occurrence =

จำนวนครั้งที่เจอ

$$w_{t,d} = \begin{cases} 1 + \log_{10} tf_{t,d} & \text{if } tf_{t,d} > 0 \\ 0 & \text{otherwise} \end{cases}$$

- $tf_{t,d}$  = จำนวนครั้งที่เจอ  $t$  ใน  $d$

# คำทุกคำไม่ได้เท่าเทียมกัน

- term ที่เห็นบ่อยๆ มักจะไม่ค่อย informative (ไม่ได้ช่วยให้หา document ได้แม่นยำขึ้น)
- $tf_{t,d}$  = ความสำคัญของ term นั้นต่อ document นั้น
- ความสำคัญของ term นั้นโดยทั่วไป?

$$\mathrm{idf}_t = \log_{10} \frac{N}{\mathrm{df}_t}$$

$$\text{idf}_t = \log_{10} \frac{N}{\text{df}_t}$$

term	$\text{df}_t$	$\text{idf}_t$
calpurnia	1	
animal	100	
sunday	1000	
fly	10,000	
under	100,000	
the	1,000,000	

# TF-IDF weighting

$$w_{t,d} = (1 + \log \text{tf}_{t,d}) \cdot \log \frac{N}{\text{df}_t}$$