

Vector Space Model for Search

TF-IDF weighting

Co-occurrence

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...		Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	157	73	0	0	1			ANTHONY	5.25	3.18	0.0	0.0	0.0	0.35	
BRUTUS	4	157	0	2	0	0		BRUTUS	1.21	6.10	0.0	1.0	0.0	0.0	
CAESAR	232	227	0	2	1	0		CAESAR	8.59	2.54	0.0	1.51	0.25	0.0	
CALPURNIA	0	10	0	0	0	0		CALPURNIA	0.0	1.54	0.0	0.0	0.0	0.0	
CLEOPATRA	57	0	0	0	0	0		CLEOPATRA	2.85	0.0	0.0	0.0	0.0	0.0	
MERCY	2	0	3	8	5	8		MERCY	1.51	0.0	1.90	0.12	5.25	0.88	
WORSER	2	0	1	1	1	5		WORSER	1.37	0.0	0.11	4.15	0.25	1.95	
...								...							

$$w_{t,d} = (1 + \log \underline{\text{tf}_{t,d}}) \cdot \log \frac{N}{\text{df}_t}$$

docs
docs with t

ทบทวน vector space model

- โมเดลความหมายของ query และความหมายของ document ด้วย vector (project query และ document ลงบน space)
- cosine similarity ในการเปรียบเทียบความหมาย

Cosine similarity ระหว่าง query กับ document

query /		The Tempest	Hamlet	Othello	Macbeth
0	ANTHONY	0.0	0.0	0.0	0.35
0	BRUTUS	0.0	1.0	0.0	0.0
1	CAESAR	0.0	1.51	0.25	0.0
0	CALPURNIA	0.0	0.0	0.0	0.0
0	CLEOPATRA	0.0	0.0	0.0	0.0
1	MERCY	1.90	0.12	5.25	0.88
1	WORSER	0.11	4.15	0.25	1.95
	...				

query

The
Tempest

		Hamlet	Othello	Macbeth
0	ANTHONY	0.0	0.0	0.35
0	BRUTUS	0.0	1.0	0.0
1	CAESAR	0.0	1.51	0.25
0	CALPURNIA	0.0	0.0	0.0
0	CLEOPATRA	0.0	0.0	0.0
1	MERCY	1.90	0.12	5.25
1	WORSER	0.11	4.15	0.25
	...			

$$\frac{1 \cdot 1.9 + 1 \cdot 0.11}{\sqrt{3} \cdot \sqrt{1.9^2 + 0.11^2}}$$

↓
relevance score

$$\cos(\vec{q}, \vec{d}) = \text{SIM}(\vec{q}, \vec{d}) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \|\vec{d}\|} = \frac{\sum_{i=1}^{|V|} q_i d_i}{\sqrt{\sum_{i=1}^{|V|} q_i^2} \sqrt{\sum_{i=1}^{|V|} d_i^2}}$$

normalization

สูตรไหนใช้ได้ก็ใช้ ใช้ไม่ได้ก็เทหิ่งไป

Term frequency	Document frequency	Normalization
n (natural) $tf_{t,d}$	n (no) 1	n (none) 1
l (logarithm) $1 + \log(tf_{t,d})$	t (idf) $\log \frac{N}{df_t}$	c (cosine) $\frac{1}{\sqrt{w_1^2+w_2^2+\dots+w_M^2}}$
a (augmented) $0.5 + \frac{0.5 \times tf_{t,d}}{\max_t(tf_{t,d})}$	p (prob idf) $\max\{0, \log \frac{N-df_t}{df_t}\}$	u (pivoted unique) $1/u$
b (boolean) $\begin{cases} 1 & \text{if } tf_{t,d} > 0 \\ 0 & \text{otherwise} \end{cases}$		b (byte size) $1/CharLength^\alpha$, $\alpha < 1$
L (log ave) $\frac{1+\log(tf_{t,d})}{1+\log(\text{ave}_{t \in d}(tf_{t,d}))}$		

ddd.qqq
Inc.ltc

สูตรใหม่ใช้ได้ก็ใช้ ใช้ไม่ได้ก็เทิ่งไป

$$\sum_w tf_{w,Q} \cdot \frac{tf_{w,D}}{tf_{w,D} + \frac{k|D|}{avg|D|}} \cdot \log \frac{|C|}{df_w}$$

Evaluation of Relevance Model

- Precision, Recall, F1

The usual

- precision
- recall
- $f_1 = 2 * (P + R) / (P * R)$

The usual

- precision
- recall
- $f1 = 2 * \underline{(P + R)} / (P * R)$

จำนวนครั้งที่ไทยถูก / จำนวนครั้งที่ไทย
จำนวนเอกสารไทยถูกกว่าเกี่ยวข้อง / จำนวนเอกสารที่นำมาให้ดู

จำนวนครั้งที่ไทยถูก / จำนวนคำตอบที่ถูก
จำนวนเอกสารไทยถูกกว่าเกี่ยวข้อง / จำนวนเอกสารที่เกี่ยวข้องทั้งหมด

Click data

~ query log
Search log

query	doc id	rank	click?
1	30	1	1
1	12	2	0
1	11	3	1
1	50	4	
2	12	1	
2	7	2	
2	30	3	
2	4	4	1

Click model

- precision@k

จำนวนเอกสารที่ถูกกว่าเกี่ยวข้อง¹

จำนวนเอกสารที่นำมาให้ดู⁴

$$\text{precision}@k = \frac{\text{จำนวนเอกสารที่ถูกกว่าเกี่ยวข้อง}}{\text{จำนวนเอกสารที่นำมาให้ดู}}$$

$\frac{1}{4}$ $\frac{2}{6}$

$\frac{1}{3}$ $\frac{2}{3}$

- recall@k

จำนวนเอกสารที่ถูกกว่าเกี่ยวข้อง¹

จำนวนเอกสารที่เกี่ยวข้องทั้งหมด³

query	doc id	rank	click?
1	30	1	1
1	12	2	0
1	11	3	1
1	50	4	0
2	12	1	0
2	7	2	0
2	30	3	0
2	4	4	1

Evaluation of Relevance Model

- nDCG

Ranking

query	doc id	rank	click?
1	30	1	1
1	12	2	0
1	11	3	1
1	50	4	0
2	12	1	0
2	7	2	0
2	30	3	0
2	4	4	1

query	doc id	rank	click?
1	30	1	1
1	11	2	1
1	12	3	0
1	50	4	0
2	4	1	1
2	7	2	0
2	30	3	0
2	12	4	0

Search results

Rank	Judgment	Discounted Gain		Ideal Discounted Gain		Normalized Discounted Gain	
		Cumulative	Gain (DCG)	Cumulative	Gain (iDCG)	Cumulative	Gain (NDCG)
1	1	2	2	3/1	3.0	2/5	0.67
1	2	0	0	2/2	1	4.0	0.5
1	3	3	3	2/3	4.67	3/1	0.64
1	4	2	2	0/4	4.67	3/5	0.75


NDCG @ 4

Evaluation of IR System

ข้อจำกัดของการใช้ Click Data

- ถ้า doc ที่ดีกว่านี้มันไม่อยู่ใน search results แล้วทำไง
- คลิกเยอะแล้วดีจริงหรือ
- คลิกน้อยแล้วดีจริงหรือ

Classic Search Model



ปัญหาของการใช้
Intrinsic evaluation

Metric มาตรวัดไหนดีกว่ากัน



Clickthrough Rate (CTR)



อัตราการสั่งอาหาร
อัตราการจองโรงแรม
อัตราการสั่งซื้อสินค้า

A/B Testing (online testing)





- Word Segmentation → Thai Character Cluster?
- วิธีการคำนวณ relevance score แบบใหม่

Step 1


- คำนวณ nDCG@k จาก click data เอามาให้แน่ใจว่าจะลอง A/B testing

Step 2 สร้าง search engine สองตัว


- Word Segmentation (ของเดิม)
- Thai Character Cluster (อยากรอง)



Step 3 ແບ່ງກລຸມຜູ້ໃຊ້



Step 4 รอนานๆ แล้วดูผล



Step 4 រອនានៅ ឡើតូអល

- ผลต่างมักจะเล็กมาก ๆ ๆ ๆ ต้องรอเก็บสถิติyeอะๆ ก็จะแน่ใจว่า ผลที่เราเห็นมีนัยสำคัญจริงๆ (ไม่ใช่ฟลุค)
 - อัตราการสংอาหารอาจจะเพิ่มจาก $0.50\% \rightarrow 0.51\%$
 0.01% อาจจะทำกับรายได้เพิ่มเป็นแสนบาทต่อปี

Step 5 គោយទាញតាមពិរនប់ថ្មី

- គោយទាញតាម traffic ថ្មីដែលមានការប្រើប្រាស់ថ្មី
- ចែករាយ effect នៃការប្រើប្រាស់ថ្មី

A/B Testing

- ข้อดี
 - ชั่วโมงกว่าตอบโจทย์ information need รีบเล่า
 - จะใช้ metric อะไรก็ได้ที่สนใจและวัดได้
- ข้อเสีย
 - ใช้เวลาเยอะ
 - ต้องระบบมาก

Semantic Search (Query Expansion)

ระบบไม่ได้แต่ความหมายจริงๆ

- รับสมัครครูมีรยม

ครู

- รับสมัครอาจารย์มีรยม

teacher (m)

- Lehrer in Berlin

(P.)

- Lehrerin in Berlin

อาจารย์

X

Lehrer/in

Lehrer ↗ in

X

Semantic Search Hack

- Hack = ลูกๆ ไม่มีหลักการ แต่ว่าลองแล้วมันดันใช้ได้

Lexical Semantics


query expansion

Word Net

Token

Lexical relation

Terms



Computational Lexical Semantics

```
>>> w2v_model.most_similar('อาจารย์')
[('คณ้าอาจารย์', 0.5376085042953491),
 ('ลูกค้าของ', 0.4775567650794983),
 ('ครู', 0.4513567388057709),
 ('นักศึกษา', 0.44001448154449463),
 ('ศาสตราจารย์', 0.4223988950252533),
 ('คิมย์ ก่า', 0.4189813733100891),
 ('อาจารย์พิเศษ', 0.4124056398868561),
 ('คิมย์', 0.40856611728668213),
 ('นักเรียน', 0.40179842710494995),
 ('รองศาสตราจารย์', 0.3998578190803528)]
```

1. Train embeddings
on docs

2. most similar
candidates

3. review
manual

Query Expansion



- ใช้ (computational) lexical semantics ในการทำความเข้าใจ query และ document

Semantic Search

(Query Understanding)


Query Understanding

- พาสต้า โรเมนติก สีลม ไม่แพง
 - ↑ Italian
 - ↑ location
 - attribute



query tagging

พาสต้า โรเมนติก สีลม เมือง



พาสต้า

Category:Italian

โรเมนติก

Location: สีลม

Attribute: ฿฿

Category:Italian

Location: สีลม

Attribute: ฿฿

บ้านเชฟ Casa Pasta

4.1 ★ 53 รีวิว เปิดอยู่

อาหารอิตาเลียน

เมนูเด็ด: Half Moon Pizza, Pizza Half Moon, rocket salad with italian sausage

citi รับส่วนลด 10% เฉพาะค่าอาหาร เมื่อทานครบ 1,000 บาทขึ้นไป / เชลล์สลิป



Category:Italian

Location: อุดมสุข

Attribute: ฿฿฿฿

Learning to Rank

ปัจจัยอื่นๆ

- ระยะห่างระหว่างคน search กับร้านอาหาร
- จำนวนดาว
- เปิดอยู่รึเปล่า

The Pasta House

4.0 ★ 39 รีวิว เปิดอยู่

อาหารอิตาเลียน, พิซซ่า

เมนูเด็ด: Pizza Pepperoni, spaghetti carbonara, Spaghetti Aglio Olio

+249

บ้านเชฟ Casa Pasta

4.1 ★ 53 รีวิว เปิดอยู่

อาหารอิตาเลียน

เมนูเด็ด: Half Moon Pizza, Pizza Half Moon, rocket salad with Italian sausage

citi รับส่วนลด 10% เฉพาะค่าอาหาร เมื่อทานครบ 1,000 บาทขึ้นไป / เชลล์สลิป

+237

ปัจจัยอื่นๆ

Zenning

- q = ใบตอบรับ อาจารย์พิทยาวัฒน์



จาก: อาจารย์พิทยาวัฒน์

หัวข้อ: อย่าลืมปิดไฟ

10 ม.ค. 2561




จาก: คณะอักษรศาสตร์


หัวข้อ: ใบตอบรับ

10 ม.ค. 2562

Features for Search



ทำนายว่าจะ doc จะถูกคลิกมั้ย



Pointwise model

γ_{label}

features

click?	Term score	Title Score	Recency
1	0.6	0.2	5
0	0.4	0.1	10
1	0.35	0.5	3
0	0.2	0.5	2
0	0.9	0.2	4
0	0.2	0.6	2
0	0.1	0.5	1
1	0.1	0.1	4

$$P(\gamma | X)$$

$$P(\text{click} | w_1, w_2, w_3)$$

$$= \beta_c$$